

# Barkiré Moussa Douramane Fanis MADOR

Octobre 2025



# Prédiction de l'attrition des employés



# PLAN



- ▶ **I. Présentation et Pré-traitement des données**
- ▶ **II. Analyse Exploratoire (EDA)**
- ▶ **III. Modélisation**
- ▶ **IV. Evaluation**
- ▶ **V. Recommandations**

# INTRODUCTION

L'attrition des employés, c'est-à-dire le départ volontaire ou involontaire d'un salarié, est un enjeu majeur pour les entreprises. Un fort taux d'attrition peut avoir un impact négatif sur la performance, engendrer des coûts élevés de recrutement et de formation, et fragiliser la stabilité des équipes.

Dans ce projet, nous cherchons à **prédire la probabilité qu'un employé quitte l'entreprise** dans les 12 prochains mois.



# I. Présentation et Pré-traitement des données



# Présentation du Dataset

- ▶ **Source et Taille:** 15 000 Observations
- ▶ **Nature :** mélange de variables numériques, catégorielles et binaires
- ▶ **Variable Cible:** Attrition (1 = départ, 0 = reste)

| Nom de la variable        | Type         | Description                                                  |
|---------------------------|--------------|--------------------------------------------------------------|
| employee_id               | id           | Identifiant unique de l'employé                              |
| age                       | numérique    | Âge de l'employé (années)                                    |
| favourite_sport           | catégorielle | Sport préféré                                                |
| years_at_company          | numérique    | Nombre d'années dans l'entreprise                            |
| job_level                 | numérique    | Niveau du poste (1–5)                                        |
| astrological_sign         | catégorielle | Signe astrologique                                           |
| monthly_income            | numérique    | Salaire mensuel (€)                                          |
| percent_salary_hike       | numérique    | Pourcentage d'augmentation salariale récente                 |
| lucky_number              | numérique    | Nombre porte-bonheur                                         |
| num_companies_worked      | numérique    | Nombre d'entreprises antérieures                             |
| training_times_last_year  | numérique    | Nombre de formations suivies l'année passée                  |
| random_note               | texte        | Note aléatoire                                               |
| work_accident             | binaire      | A subi un accident du travail (0/1)                          |
| overtime                  | catégorielle | Fait des heures sup (Yes/No)                                 |
| job_satisfaction          | numérique    | Satisfaction au travail (1–5)                                |
| environment_satisfaction  | numérique    | Satisfaction de l'environnement (1–5)                        |
| last_evaluation           | numérique    | Score d'évaluation de performance (0–1)                      |
| promotion_last_5years     | binaire      | Promotion au cours des 5 dernières années (0/1)              |
| education_level           | catégorielle | Niveau d'études (HighSchool, Bachelors, Masters, PhD, Other) |
| distance_from_home        | numérique    | Distance domicile-travail (km)                               |
| marital_status            | catégorielle | Statut marital (Single, Married, Divorced)                   |
| department                | catégorielle | Département (Sales, R&D, HR, IT, Finance, Operations)        |
| browser_theme_color       | catégorielle | Couleur thème navigateur                                     |
| employee_engagement_score | numérique    | Score d'engagement (0–100)                                   |
| attrition                 | binaire      | <b>Cible</b> : 1 = l'employé a quitté, 0 = reste             |

# Pré-traitement des données

Certaines variables du jeu de données **n'apportent aucune valeur prédictive** ou sont sans lien logique avec le départ d'un employé.


| Variable            | Type         | Raison de suppression                                               |
|---------------------|--------------|---------------------------------------------------------------------|
| employee_id         | Identifiant  | Sert uniquement à identifier un employé, aucune valeur explicative. |
| favourite_sport     | Catégorielle | Variable aléatoire sans lien avec le comportement professionnel.    |
| lucky_number        | Numérique    | Donnée arbitraire sans signification statistique.                   |
| astrological_sign   | Catégorielle | Variable sans relation rationnelle avec l'attrition.                |
| browser_theme_color | Catégorielle | Variable esthétique sans impact RH.                                 |
| random_note         | Texte libre  | Contient des notes aléatoires non exploitables                      |

# II. Analyse Exploratoire (EDA)



# Variable Cible

- ▶ **12 376** ( $\approx 82.5\%$ ) ont quitté l'entreprise
- ▶ **2 624** ( $\approx 17.5\%$ ) sont restés
- ▶ Le jeu de données est **fortement déséquilibré**.
- ▶ Un modèle naïf qui prédirait toujours "1" (quitte) aurait déjà **82.5% de précision**, ce qui serait **trompeur**




# Statistiques descriptives







- ▶ Les employés ont en moyenne **41 ans**, avec une ancienneté d'environ 20 ans.
- ▶ Le revenu mensuel est très asymétrique : la majorité gagne moins de **1 000 €**, mais certains touchent jusqu'à **6 000 €**.
- ▶ Le pourcentage d'augmentation salariale est modeste (**médiane à 5 %**, max à **25 %**).  
Les employés ont travaillé dans 2 entreprises en moyenne, avec quelques cas extrêmes (jusqu'à 12).
- ▶ La majorité suit peu de formations (1 ou 2 par an), et les évaluations tournent autour de **0.6**.
- ▶ La distance domicile-travail est faible pour la majorité (**moyenne ≈ 10 km**), mais peut atteindre 90 km.  
Enfin, le score d'engagement est centré autour de **70 sur 100**.

|                           | count   | mean   | std    | min  | 25%   | 50%   | 75%    | max    |
|---------------------------|---------|--------|--------|------|-------|-------|--------|--------|
| age                       | 15000.0 | 40.98  | 13.48  | 18.0 | 30.0  | 41.0  | 53.00  | 64.0   |
| years_at_company          | 15000.0 | 19.56  | 11.52  | 0.0  | 10.0  | 20.0  | 29.00  | 39.0   |
| monthly_income            | 15000.0 | 792.69 | 525.83 | 77.0 | 442.0 | 657.0 | 993.25 | 5975.0 |
| percent_salary_hike       | 15000.0 | 6.83   | 7.15   | 0.0  | 0.0   | 5.0   | 10.00  | 25.0   |
| num_companies_worked      | 15000.0 | 2.00   | 1.42   | 0.0  | 1.0   | 2.0   | 3.00   | 12.0   |
| training_times_last_year  | 15000.0 | 1.21   | 1.10   | 0.0  | 0.0   | 1.0   | 2.00   | 8.0    |
| last_evaluation           | 15000.0 | 0.60   | 0.15   | 0.0  | 0.5   | 0.6   | 0.70   | 1.0    |
| distance_from_home        | 15000.0 | 9.86   | 9.89   | 0.0  | 3.0   | 7.0   | 14.00  | 90.0   |
| employee_engagement_score | 15000.0 | 69.83  | 14.51  | 10.0 | 59.9  | 69.9  | 80.00  | 100.0  |










# Analyse Univariée (Variables Numériques)










# Analyse Univariée (Variables Catégorielles)









# Analyse Univariée (Valeurs Extrêmes)



# Analyse Bivariée (attrition et Variables numériques)




# Analyse Bivariée (Attrition et Variables Catégorielles)




# Matrice de Corrélation

l'attrition augmente avec le salaire mensuel, indiquant que les employés percevant des salaires faible quittent plus souvent.

Les autres variables numériques, comme l'âge, l'ancienneté ou le nombre d'entreprises précédentes, ont une corrélation quasi nulle avec la cible.



# III. Modélisation



# Préparation des données

## ➤ Définition des ensembles


**Méthode:** Séparer les données pour **évaluer la performance réelle** du modèle. L'ensemble d'entraînement (80%) et l'ensemble de test (20%)

## ➤ Rééquilibrage des données

**Méthode:** SMOTE (Synthetic Minority Over-sampling Technique). Génère artificiellement de nouvelles observations de la classe minoritaire. Afin obtenir un jeu d'entraînement équilibré (50/50 environ).

## ➤ Normalisation des données numériques


**Méthode:** Standardisation des données




Le modèle KNN, avec un  $k$  optimal de 6, obtient une bonne performance globale ( $AUC = 0,75$ ) et prédit efficacement les départs d'employés ( $rappel = 0,95$ ), bien qu'il ait plus de difficultés à identifier ceux qui restent.

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.62      | 0.38   | 0.47     | 525     |
| 1            | 0.88      | 0.95   | 0.91     | 2475    |
| accuracy     |           |        | 0.85     | 3000    |
| macro avg    | 0.75      | 0.67   | 0.69     | 3000    |
| weighted avg | 0.83      | 0.85   | 0.84     | 3000    |

ROC-AUC Score: 0.753031265031265



# Bagging (Base Tree decision)



--- PERFORMANCES FINALES du modèle Bagging sur l'Ensemble de Test ---

Modèle : Bagging Classifieur avec n\_estimators=800.

Accuracy : 0.8530

F1-score (macro avg) : 0.7317


AUC ROC : 0.8336

Rapport de Classification :

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.59      | 0.52   | 0.55     | 525     |
| 1            | 0.90      | 0.92   | 0.91     | 2475    |
| accuracy     |           |        | 0.85     | 3000    |
| macro avg    | 0.75      | 0.72   | 0.73     | 3000    |
| weighted avg | 0.85      | 0.85   | 0.85     | 3000    |

- Le modèle **Bagging** basé sur des **arbres de décision** atteint une **bonne performance globale (AUC = 0,83 ; accuracy = 85 %)**, avec une excellente capacité à prédire les employés quittant l'entreprise (rappel = 0,92).
- Cependant, il reste moins performant pour identifier ceux qui restent, avec une précision modérée sur la classe « Reste » (0,59).

# Random Forest



--- PERFORMANCES FINALES du modèle Random Forest sur l'Ensemble de Test ---

Accuracy : 0.8547

F1-score (macro avg) : 0.7376

AUC ROC : 0.8406


Rapport de Classification :

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.59      | 0.53   | 0.56     | 525     |
| 1            | 0.90      | 0.92   | 0.91     | 2475    |
| accuracy     |           |        | 0.85     | 3000    |
| macro avg    | 0.75      | 0.73   | 0.74     | 3000    |
| weighted avg | 0.85      | 0.85   | 0.85     | 3000    |

- Le modèle **Random Forest** obtient une **bonne performance globale** avec une **accuracy de 85 %** et un **AUC de 0,84**, indiquant une excellente capacité de discrimination.
- Il prédit efficacement les départs d'employés (rappel = 0,92) tout en restant modérément précis pour la classe « Reste » (précision = 0,59).

# XGBOOST

- ▶ Le modèle XGBoost affiche la meilleure précision globale (86,8 %) et un AUC de 0,82 ; démontrant une très bonne capacité de généralisation.
- ▶ Il identifie remarquablement bien les employés quittant l'entreprise (rappel = 0,96), mais reste moins performant pour prédire ceux qui restent (rappel = 0,45).



--- PERFORMANCES FINALES du modèle XGBoost sur l'Ensemble de Test ---

Accuracy : 0.8683

F1-score (macro avg) : 0.7337

AUC ROC : 0.8242

Rapport de Classification :

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.69      | 0.45   | 0.54     | 525     |
| 1            | 0.89      | 0.96   | 0.92     | 2475    |
| accuracy     |           |        | 0.87     | 3000    |
| macro avg    | 0.79      | 0.70   | 0.73     | 3000    |
| weighted avg | 0.86      | 0.87   | 0.86     | 3000    |

# IV. Evaluation




# Tableau Comparatif

- ▶ Le **Random Forest** et le **XGBoost** sont les modèles les plus performants, avec des **AUC supérieurs à 0,82** et des **F1-scores autour de 0,73**, indiquant une bonne capacité de généralisation.
- ▶ Le **KNN** présente les performances les plus faibles, confirmant que les méthodes d'ensemble offrent une meilleure robustesse pour prédire l'attrition.
- ▶ le **meilleur modèle** est **RandomForest**

--- Tableau Comparatif Final des Modèles ---

|              | Accuracy | F1 (macro) | AUC    |
|--------------|----------|------------|--------|
| RandomForest | 0.8547   | 0.7376     | 0.8406 |
| Bagging      | 0.8530   | 0.7317     | 0.8336 |
| XGBoost      | 0.8683   | 0.7337     | 0.8242 |
| k-NN         | 0.8500   | 0.6900     | 0.7500 |

# Importance des Variables



# V. Recommendations



# Recommandations

- ▶ **Stratégie de Rémunération (monthly\_income)** : Étant le facteur le plus influent, la politique salariale doit être la priorité. Il est recommandé de mener une analyse pour s'assurer que les salaires sont compétitifs par rapport au marché et de considérer des ajustements ciblés pour les populations identifiées comme les plus à risque par le modèle.
- ▶ **Développement et Conditions de Travail** : Les variables `training_times_last_year` et `distance_from_home` sont importantes. L'entreprise pourrait investir dans des opportunités de formation pour augmenter l'engagement et explorer des politiques de travail plus flexibles (télétravail) pour réduire l'impact négatif de la distance.
- ▶ **Suivi du Bien-être** : Les scores de satisfaction et d'engagement sont des prédicteurs clés. Mettre en place des sondages réguliers et des plans d'action basés sur leurs résultats pour améliorer l'environnement de travail est une stratégie proactive pour retenir les talents.



Nous vous remercions de votre  
bienveillante attention

